ساختمان داده ها و الگوریتم ها

نیم‌سال اول ۱۳۹۹ـ۱۴۰۰

دکتر صفرنژاد

دانشکده‌ی مهندسی کامپیوتر

فاز اول چالش — طراحی یک ماشین جستجوی ساده

هدف چالش: استفاده از ساختار درخت برای پیدا کردن یک regex در متن

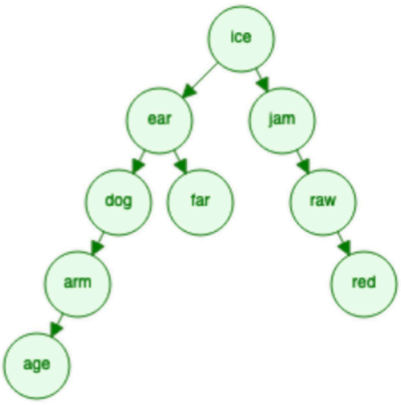
امروزه استفاده از موتورهای جست‌وجو فرایند یادگیری و جمع‌آوری اطلاعات را تسریع بخشیده است. معیارهای مختلفی برای مقایسه موتورهای جست‌وجو وجود دارد که از میان آن‌ها، سرعت یافتن پاسخ و همچنین در نظر گرفتن تمام پاسخ‌های احتمالی از فاکتورهای مهم در این سرویس‌هاست.

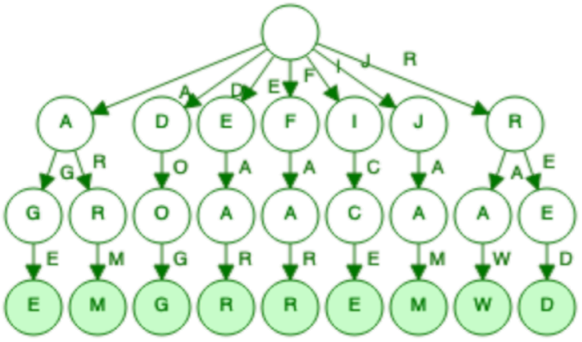
در فاز اول چالش، از شما خواسته می‌شود که با در اختیار داشتن یک متن، درخت جست‌وجوی مناسبی متناظر با آن بسازید. پس از آن، کلماتی به شما داده می‌شوند که به صورت regex با یک ترکیب ’\S*‘ هستند. در هنگام استفاده از regex ، کاراکتر ’\S‘ با هر کاراکتر دلخواهی (به جز whitespace ها) match می‌شود و کاراکتر ’*‘ به معنای تعداد دلخواهی تکرر می‌باشد؛ بنابراین منظور از وجود ترکیب ’\S*‘ این است که هر تعداد کاراکتر دلخواهی می‌توانند در کلمه وجود داشته باشند. برای مثال در زمان جست‌وجوی ’asi\S*‘ ، کلمات ’asinine‘ ، ’aside‘ و ’asiatic‘ پیدا می‌شوند.

انتخاب ساختار درختی مناسب برای جست‌وجو در متن بر عهده شماست. شما می‌توانید هر نوع ساختار درختی را مورد استفاده قرار دهید، اما توجه داشته باشید که در فاز دوم، عملیات جست‌وجو سنگین‌تر خواهد بود، بنابراین پیاده‌سازی درختی بهینه در این فاز به نفع شماست.

نمونه: فرض کنید متن شما از ۹ کلمه موجود در جدول تشکیل شده باشد. برای این کلمات، شما می‌توانید ساختارهای درختی متنوعی را در نظر بگیرید. برای مثال پیاده‌سازی Binary search tree (شکل چپ) و Trie (شکل راست) به صورت زیر خواهد بود:

ice	ear	jam	dog	far	raw	red	arm	age





حال کافیست با دریافت regex ، کلمات متناظر را از ساختار درختی استخراج کرده و در خروجی نمایش دهید. برای مثال؛ در جواب به کوئری "\S*r" ، شما باید بتوانید هر دو کلمه ear و far را پیدا کنید. توجه کنید که ترکیب '\S*' می‌تواند در هر محلی از regex مورد جست‌وجو قرار داشته باشد، بنابراین در هنگام پیاده‌سازی ساختار درختی خود این موضوع را در نظر داشته باشید.

نکات مهم در رابطه با چالش:

- اهداف اصلی این فاز، پیاده‌سازی درختی متن و یافتن تمام کلمات منطبق بر regex است. استفاده از داده‌ساختارهای دیگر در کنار درخت مانعی ندارد.
- با وجود اینکه محدودیتی بر روی ساختار درخت انتخابی شما وجود ندارد، تلاش کنید بهینه‌ترین حالت ممکن را پیاده‌سازی کنید. فاز دوم چالش به صورت رده‌بندی بوده و زمان یافتن پاسخ در کنار درستی آن اهمیت می‌یابد. دقت کنید در صورتی که درخت شما متوازن نباشد ممکن است به حالت بهینه نرسید.
- برای پیاده‌سازی بخش جست‌وجوی regex ، می‌توانید درباره wildcard query مطالعه نمایید.

ورودی و خروجی ها:

در خط اول ورودی دو عدد n و q به ترتیب آمده‌اند. n نشان‌دهنده‌ی تعداد کلمات است. q نشان‌دهنده‌ی تعداد کوئری ها است. در خط بعدی n کلمه که با فاصله از هم جدا شده‌اند به شما داده می‌شود. در هر یک از q خط بعدی یک کوئری در اختیار شما قرار می‌گیرد.
شما باید در خط m اُم خروجی ابتدا تعداد کلماتی که برای کوئری m اُم بازیابی کرده‌اید و سپس تعداد کلماتی که با کوئری m اُم match می شوند را خروجی دهید. (ترتیب خروجی دادن کلمات مهم نیست)
برای فهم بهتر نحوه ورودی و خروجی دادن می توانید فایل های input.txt و output.txt را مشاهده کنید.

موفق باشید :)