ساختمان داده‌ها و الگوریتم‌ها

نیم‌سال اول ۱۳۹۹ـ۱۴۰۰

دکتر مهدی صفرنژاد

دانشکده‌ی مهندسی کامپیوتر

فاز دوم چالش — طراحی یک ماشین جستجوی ساده

هدف: پیدا کردن متن های حاوی یک regex مشخص با کمک ساختار های درختی و جدول درهم‌سازی

در این مرحله، شما به عملکرد موتور جست‌وجو نزدیک‌تر می‌شوید. در ابتدا چندین متن همراه با DocID در اختیار شما قرار داده می‌شوند (فرمت نام فایل‌ها به صورت DocIDxx.txt است که xx عدد متناظر با شماره متن است). سپس به ازای هر کوئری، لازم است متن‌های حاوی پرسش مورد نظر در خروجی به کمک DocID نمایش داده شوند. مثال زیر به فهم بیشتر موضوع کمک می‌کند :
فرض کنید تعداد متن‌های ورودی برابر با ۳تاست و به صورت زیر هستند:

DocID۰۱.txt	DocID۰۲.txt	DocID۰۳.txt
Asdfg	As	Cv
Zxcv	Askew	Luhefhj
Qwer	Asytre	pergh
Poiu	Aspuoiy	
plkm	s	

در این صورت با دیدن ورودی 'as\S*' مقادیر ۱ و ۲ خروجی داده می‌شوند. در متن اول کلمه Asdfg و در متن دوم کلمات As، Asytre Askew و Aspuoiy با پرسش مطرح شده منطبق هستند. همچنین با ورودی 'cv*S\' مقادیر ۱ و ۳ در خروجی ظاهر می‌شوند. (Zxcv و Cv)

نکات مهم در رابطه با چالش:

- با توجه به اینکه می‌توان با ایجاد تغییراتی در ساختار درختی فاز اول این فاز را نیز پیاده‌سازی کرد، استفاده از hashtable و الگوریتم‌های مشابه ضروری است بنابراین در پیاده‌سازی خود حتما این مورد را در نظر بگیرید.
- استفاده از درختی متفاوت با درخت پیشنهادی شما در فاز اول ایرادی ندارد.
- کلمات موجود در متن‌ها ممکن است hyphenated باشند و با حروف بزرگ یا کوچک نوشته شده باشند.

برای یکسان‌سازی تمامی پرسش‌ها و پاسخ‌ها، می‌توانید hyphen ها را حذف کنید و تمامی حروف بزرگ را به حروف کوچک تبدیل کنید.

- longterm <- Long-Term
- abcdefg <- AbCdEfG

- هر زبان برنامه‌نویسی رده‌بندی خود را دارد و جدول رده‌بندی زبان‌ها مشترک نخواهد بود.
- همان‌طور که در مثال مطرح شده در بالا نیز مشخص است، برای کوئری ’as\S*’ در متن اول تنها ۱ کلمه و در متن دوم ۴ کلمه پیدا شده‌اند. واضح است که متن دوم مشابهت‌های بیشتری دارد و در نتیجه اهمیت بالاتری پیدا می‌کند. در زمان خروجی دادن لازم است این رده‌بندی بر اساس تعداد کلمه‌های match شده در متن‌ها رعایت شود. اگر دو متن تعداد کلمات مساوی داشته باشند ترتیب آنها اهمیتی ندارد.
- مورد امتیازی:
  - حافظه: درست است که حافظه جزو شرایط مسئله نبوده است اما در عمل اهمیت بالایی دارد. حافظه کم در پیاده‌سازی به عنوان امتیاز مثبت در نظر گرفته خواهد شد.

از آنجایی که زمان فاز اول چالش هنوز به پایان نرسیده است، جدول رده‌بندی و داوری برای فاز دوم تا یک هفته فعال نمی‌شود. توضیحات درباره نحوه عملکرد judge و تعیین زمان کدها با ددلاین فاز اول در اختیار شما قرار خواهد گرفت. فایل‌های متنی لازم برای استفاده در این فاز ضمیمه شده‌اند.

موفق باشید :)